



Human-in-the- Loop UX – Khi Nào Agent Cần Xin Phép?

AICB-P2T3 · Ngày 27 · Chương 6 – Agent trong Production

Giảng viên

“Agent tự quyết hay hỏi người dùng – ranh giới nào là an toàn và không làm phiền?”


Giữ câu hỏi này trong đầu suốt buổi học hôm nay

1. Tại sao Full Autonomy nguy hiểm?
2. HITL Taxonomy – 5 Interaction Patterns
3. Confidence Routing – Khi nào interrupt?
4. Approval Workflows & Implementation
5. Feedback Loops & Audit Trails
6. HITL UX Best Practices
7. Demo & Thực hành

Tại sao Full Autonomy nguy hiểm?

Từ sự cố thực tế đến nhu cầu Human-in-the-Loop





Sự cố thực tế:

- Agent CS auto-refund \$50K không cần duyệt
- Code agent xoá branch production
- Email agent gửi nội bộ ra ngoài

Lưu ý: Full autonomy chỉ an toàn khi mọi action đều **reversible** và **low-cost**. Trong thực tế, rất ít action thoả mãn cả hai.




Dưới threshold → agent tự xử lý
Vùng trung gian → cần 1 lần duyệt

Rủi ro cao → phải escalate lên người có thẩm quyền

Cùng nguyên tắc: chi phí sai làm quyết định mức kiểm soát

HITL Taxonomy – 5 Interaction Patterns

Phân loại cách con người tham gia vào quyết định của agent



Không có vị trí “đúng” cố định – sweet spot phụ thuộc vào **domain risk**, **agent maturity**, và **user tolerance**. Bắt đầu strict, nới dần khi trust được xây dựng.

#	Pattern	Khi nào?	Ví dụ
1	Approval	Action cao rủi ro	Deploy, xoá data, gửi email
2	Clarification	Input mơ hồ	“Bạn muốn report Q1 hay Q2?”
3	Escalation	Vượt khả năng	Câu hỏi pháp lý, tài chính
4	Review Checkpoint	Kết quả cần kiểm	Draft email, code PR
5	Edit / Correction	User muốn chỉnh	Sửa nội dung trước gửi

Read-only = auto

Write/Update = log + optional approval


Delete/Deploy = mandatory approval

Review: approve/reject nguyên bản

Edit: human chỉnh sửa nội dung
Common cho content generation tasks

Confidence Routing – Khi nào interrupt?

Agent tự đánh giá confidence để quyết định hỏi hay tự làm



Lưu ý: Dù confidence = 0.99, agent vẫn **PHẢI** dừng nếu action vi phạm policy cố định (dữ liệu nhạy cảm, email external, deploy production).

\$10

Cost of error
thấp → dừng hỏi

0.70

Confidence
threshold mặc định


\$10K

Cost of error
cao → luôn hỏi

Đo **accuracy vs confidence** trên historical data. Nếu confidence 0.80 mà accuracy chỉ 60% → threshold quá thấp, cần nâng lên. Đây là **empirical tuning**, không có magic number.

Approval Workflows & Implementation

LangGraph interrupt/resume và Streamlit approval UI



Hai loại interrupt:

- interrupt_before: pause **trước** destructive action
- interrupt_after: pause **sau** draft generation (review trước send)

1. Xem pending action + confidence
2. Human approve/reject/edit
3. Update state → continue graph
4. Multi-step: nhiều interrupt points

```
# Compile with interrupt
graph = builder.compile(
    interrupt_before=["delete_action"],
    checkpointer=MemorySaver(),
)

# Run until interrupt
state = graph.invoke(input, config)
print(state["pending_action"])
# => {"action": "delete_user",
#     "confidence": 0.62}

# Human approves -> resume
graph.update_state(
    config, {"approved": True}
)
result = graph.invoke(None, config)
```

3 bước implement:

1. **Define interrupt nodes:** liệt kê tất cả destructive actions
2. **State inspection:** pending action + confidence + reasoning
3. **Resume logic:** update approved/rejected rồi continue

Lưu ý: Luôn dùng checkpointer – không có persistence, graph “quên” state khi interrupt.

Agent Approval Request

Action: `delete_user(id=42)`

Confidence: **62%** (below threshold)

Reason: "User inactive 2 years"

- user: {id: 42, name: "Nguyễn", status: active}

Approve

Reject

Edit

UI components:

1. **Action card:** hiển thị pending action + confidence
2. **Reasoning:** giải thích tại sao agent muốn làm
3. **Diff view:** proposed changes highlighted
4. **3 buttons:** Approve / Reject / Edit

Mobile: Telegram bot approve/reject

Batch: group low-risk actions → approve in bulk để giảm fatigue

Feedback Loops & Audit Trails

Thu thập phản hồi, ghi log, và tăng autonomy dần


```
class AuditEntry(BaseModel):
    timestamp: datetime
    agent_id: str
    action: str
    confidence: float
    risk_level: str # low/med/high
    reviewer_id: str | None
    decision: str # auto/approve/reject
    reason: str | None
    execution_time_ms: int
```

```
# Immutable: append-only PostgreSQL
# Backup: S3 daily snapshot
# Replay: reconstruct full session
```

Mỗi event ghi:

- **Who:** agent nào, reviewer nào
- **What:** action gì, confidence bao nhiêu
- **When:** timestamp chính xác
- **Why:** reasoning của agent + decision

Lưu ý: Audit trail là **compliance requirement** (GDPR, SOC2). Build from day one – **cannot retrofit** sau khi đã production.



3 metrics quan trọng:

1. **Approval rate:** cao → agent đáng tin, nới dần autonomy
2. **Response time:** lâu → UI gây phiền, cần batch approval
3. **Override rate:** cao → confidence calibration sai

Track metrics theo thời gian.
Approval rate ổn định $> 90\%$ →
tăng auto threshold.
Trust builds incrementally.

HITL UX Best Practices

Thiết kế trải nghiệm không làm phiền user

- 1 **Start strict, loosen gradually** – bắt đầu duyệt mọi thứ, nới dần khi agent chứng minh tin cậy
- 2 **Preemptive clarification** – detect ambiguity **ở đầu vào**, không phải giữa chừng execution
- 3 **Explainable proposals** – “Confidence 65% because [X]” giúp human quyết nhanh hơn
- 4 **Batch approvals** – group low-risk actions → approve in bulk để giảm interrupt fatigue
- 5 **Progressive autonomy** – track approval rate over time, auto-adjust threshold

Demo & Thực hành

HITL Code Review Agent + Lab hands-on

07

1. Agent đọc PR, phân tích code changes, đề xuất review comments
2. Confidence 72%: hiển thị diff + reasoning → user Approve → agent commit
3. Confidence 58%: escalate – hiển thị context + câu hỏi cụ thể cho reviewer
4. Mỗi interaction ghi vào PostgreSQL audit trail – replay full session

Mục tiêu: Build HITL agent với LangGraph interrupt + Streamlit approval UI

Deliverable: HITL agent + approval UI + confidence-based routing + PostgreSQL audit trail

Thời gian: 2 giờ

1. **Approval workflow:** LangGraph `interrupt_before` cho delete/deploy actions
2. **Confidence routing:** auto khi ≥ 0.85 , suggest khi $0.70-0.85$, ask khi < 0.70
3. **Streamlit UI:** action card + diff view + Approve/Reject/Edit buttons
4. **Audit trail:** PostgreSQL append-only log, replay session, export report

A/B test: full-auto vs HITL – đo user trust score và task success rate trên 20 test cases

Những ý chính cần nhớ sau buổi học hôm nay

- 1 HITL là **responsible deployment** – xây dựng trust incrementally, không phải dấu hiệu yếu kém
- 2 Confidence routing: **3 vùng** (auto / suggest / ask) + policy override cho high-risk actions
- 3 Audit trail là compliance requirement – build from day one, **cannot retrofit** sau khi production
- 4 Progressive autonomy: start strict, đo metrics, nói dần – approval rate $> 90\%$ là tín hiệu tốt

Ngày 28: Workshop Tổng Hợp – Full Production Agent System

“Tất cả components đã build xong – N28 là ngày ghép lại thành hệ thống production hoàn chỉnh”

- Hoàn thành Lab 27: HITL agent + audit trail
- Review lại tất cả labs N16–N27 – chuẩn bị integration

Hỏi & Đáp

HITL có làm chậm agent không? Khi nào nên bỏ approval gate?



Cảm ơn!

AICB-P2T3 · Ngày 27 · Human-in-the-Loop UX

`github.com/vinuni-aicb`

Liên hệ: `instructor@vinuni.edu.vn`